# 大数据处理综合实验:实验2 —— 实验报告

小组 10

# 基础功能:倒排索引

# 一、设计思路

- (1) Mapper 类(InvertedIndexMapper):
  - Key 类型:输入的键是 `Object`,这通常是 Hadoop 的默认值,但实际上它不被用到。文本内容会被忽略,因为每一行都被解析为 `Text`。
  - Value 类型:输入的值是 `Text` 类型,代表了文档的内容。

# 思路:

- 每个 Mapper 实例负责处理一个文档。
- 在 `map` 方法中, 首先获取当前处理的文档名(文件名), 然后将文本内容拆分为单词。
- 对于每个单词,将其设置为输出的 Key, 文档名设置为输出的 Value, 然后写出。
- (2) Reducer 类(InvertedIndexReducer):
  - Key 类型:输入的键是 `Text`,代表了单词。
  - Value 类型: 输入的值是 `Text`, 代表了包含该单词的文档名。

## 思路:

- 每个 Reducer 实例负责处理一个唯一的单词。
- 在 `reduce` 方法中,对于每个单词,遍历其对应的文档名列表,计算每个文档名的出现次数:数并累加总出现次数。
- 然后将计算出的每个文档名的出现次数和总出现次数写入输出。
- 输出的 Key 仍然是单词,但 Value 是一个包含了各文档名及其出现次数的字符串。

总体来说,Map 阶段负责将文档拆分为单词并将其发送到对应的 Reducer,而 Reduce 阶段则负责计算每个单词在各文档中的出现次数,并输出倒排索引结果。

#### (3) 伪代码

MapReduce 中 Map 和 Reduce 的伪代码。

```
function map(key, value, context):
    fileName = getFileName(context.getInputSplit())
    tokens = splitText(value)
    for token in tokens:
        emitIntermediate(token, fileName, context)

function getFileName(inputSplit):
    return inputSplit.getPath().getName()

function splitText(text):
    return text.split("[\\s,]+")

function emitIntermediate(key, value, context):
    context.write(key, value)
```

```
function reduce(key, values, context):
   countMap = initializeEmptyHashMap()
   totalCount = 0
    for value in values:
       fileName = value
        incrementCount(countMap, fileName)
       totalCount = totalCount + 1
   averageFrequency = calculateAverageFrequency(totalCount, countMap.size())
   output = generateOutputString(averageFrequency, countMap)
   context.write(key, output)
function initializeEmptyHashMap():
   return new HashMap()
function incrementCount(countMap, fileName):
   if countMap.containsKey(fileName):
       countMap.put(fileName, countMap.get(fileName) + 1)
   else:
       countMap.put(fileName, 1)
function\ calculate Average Frequency (total Count,\ number Of Files):
   return totalCount / numberOfFiles
function generateOutputString(averageFrequency, countMap):
   output = formatAverageFrequency(averageFrequency)
   output = output + ",
    for entry in countMap.entrySet():
       output = output + entry.getKey() + ":" + entry.getValue() + ";"
   return output
function formatAverageFrequency(averageFrequency):
   return String.format("%.2f", averageFrequency)
```

## 二、实验结果

输出文件路径: /outputSS/part-r-00000

# (1) 输出结果文件的部分截图

```
''All 1.00,shakespeare-lovers-62.txt:1;
''Among 1.00,shakespeare-lovers-62.txt:1;
''And 1.00,shakespeare-lovers-62.txt:1;
'But 1.00,shakespeare-lovers-62.txt:1;
'Gamut' 1.00,shakespeare-taming-2.txt:1;
'How 1.00,shakespeare-lovers-62.txt:1;
"LO
               2.00.shakespeare-lovers-62.txt:2:
''Look 1.00, shakespeare-lovers-62.txt:1;
''My 1.00, shakespeare-lovers-62.txt:1;
''My 1.00, shakespeare-lovers-62.txt:1;
''Now 1.00, shakespeare-lovers-62.txt:1;
              2.00, shakespeare-lovers-62.txt:2;
1.00, shakespeare-merry-15.txt:1;
1.00, shakespeare-lovers-62.txt:1;
  ''0
''Od's
''The
 ''Tis
              2.00, shakespeare-comedy-7.txt:1; shakespeare-venus-60.txt:5; shakespeare-sonnets-59.txt:1; shakespeare-as-12.txt:1; 1.00, shakespeare-lovers-62.txt:1; 1.00, shakespeare-alls-11.txt:1;
''When
'twas 1.00, shakespeare-two-18.txt:1;
'twas 1.00, shakespeare-two-18.txt:2; shakespeare-twelfth-20.txt:9; shakespeare-hamlet-25.txt:3; shakespeare-troilus-22.txt:1; shakespeare-loves-8.txt:5; shakespeare-alls-11.txt:2; shakespeare-life-54.txt:1;
'--My 1.00,shakespeare-king-45.txt:1;
'--0 1.00,shakespeare-troilus-22.txt:1;
'--every 1.00,shakespeare-second-52.txt:1;
'--or 3.00,shakespeare-midsummer-16.txt:3;
'A 1.63, shakespeare-antony-23.txt:1; shakespeare-venus-60.txt:1; shakespeare-hamlet-25.txt:1; shakespeare-third-53.txt:2; shakespeare-third-53.txt:2; shakespeare-othello-47.txt:3; shakespeare-midsummer-16.txt:1; shakespeare-life-54.txt:2;
 'ARTEMIDORUS.' 1.00, shakespeare-julius-26.txt:1;
'Above 1.00, shakespeare-twelfth-20.txt:1;
'Achilles 2.00, shakespeare-troilus-22.txt:2;
                              1.00, shakespeare-life-54.txt:1
                              1.00, shakespeare-measure-13.txt:1;
heart--play
heart--that
                              1.00, shakespeare-cymbeline-17.txt:1;
                              1.00, shakespeare-tymbeline-17.tx:1;
1.00, shakespeare-hamlet-25.txt:1;
1.67, shakespeare-tragedy-57.txt:3; shakespeare-third-53.txt:1; shakespeare-troilus-22.txt:1;
1.00, shakespeare-merry-15.txt:1;
1.00, shakespeare-merry-15.txt:1;
1.00, shakespeare-first-51.txt:1;
heart-ache
heart-blood
heart-break.
heart-burned
heart-burned.
heart-burning
                              1.00.shakespeare-loves-8.txt:1;
heart-easing 1.00, shakespeare-rape-61.txt:1;
heart-grief 1.00, shakespeare-life-54.txt:1;
heart-heaviness 1.00, shakespeare-as-12.txt:1;
heart-inflaming 1.00, shakespeare-sonnets-59.txt:1;
heart-poor 1.00, shakespeare-rape-61.txt:1;
heart-sick. 1.00, shakespeare-cymbeline-17.txt:1;
heart-sore 2.00, shakespeare-two-18.txt:2;
heart-sorrow 1.00, shakespeare-tempest-4.txt:1;
heart-sorrowing 1.00, shakespeare-tragedy-58.txt:1;
heart-string 1.00, shakespeare-life-54.txt:1;
heart-string
heart-strings
heart-strings.
                             1.00, shakespeare-tragedy-58.txt:1; shakespeare-rape-61.txt:1; 1.00, shakespeare-two-18.txt:1;
                              1.00, shakespeare-king-45.txt:1;
heart-struck
heart-whole.
                             1.00, shakespeare-as-12.txt:1;
```

## (2) Yarn Resource Manager 的 WebUI 执行报告内容



Scheduler

· Tools

## Application application\_1678703754602\_9932

